

GeoVision-CLIP Cali: Estimación Espacio-Temporal de Contaminación Atmosférica mediante CLIP, SAE, ConvLSTM y ST-Kriging

Sebastián Belalcázar*, Manuel Gruezo†, Luis Angel García García‡

Ingeniería de Datos e Inteligencia Artificial

Universidad Autónoma de Occidente, Cali, Colombia

*sebastian.belalcazar@uao.edu.co †manuel.gruezo@uao.edu.co ‡luis.garcia@uao.edu.co

Resumen—Se presenta GeoVision-CLIP Cali, un sistema integral para la estimación espacio-temporal de concentraciones de NO_2 , SO_2 y O_3 sobre el área metropolitana de Cali, Colombia. El sistema integra cuatro componentes: (i) un modelo de aprendizaje contrastivo visual-textual basado en RemoteCLIP ViT-B/32 con Sparse Autoencoders k -sparse, que alcanza Recall@1 = 0.6043 en test sobre el dataset PDF v10/v5b de 1500 pares; (ii) un análisis factorial exploratorio y confirmatorio sobre embeddings visuales que cumple CFI = 0.9465 y RMSEA = 0.0312; (iii) una etapa predictiva ConvLSTM bidireccional + ST-Kriging residual, con RMSE LOO-CV T+1 de 3.895 para SO_2 y 8.515 para O_3 , R^2 promedio evaluable de 0.807 y cobertura empírica 95 % de 0.939; y (iv) despliegue completo en producción con backend FastAPI y frontend React+Vite+Leaflet en HuggingFace Spaces. Todo el sistema se desarrolló bajo restricciones estrictas de reproducibilidad (SEED=42, requirements fijados, MD5 verificado del checkpoint seleccionado) y sin filtración de datos. Los mapas finales muestran autocorrelación espacial significativa en los 9 mapas contaminante-horizonte (Moran I $\in [0,898, 0,957]$, $p = 0,001$), con LISA local, K-Means de perfiles críticos y restricciones físicas para evitar concentraciones negativas.

Index Terms—Sentinel-5P, CLIP, Sparse Autoencoders, ConvLSTM, ST-Kriging, Moran I, LISA, contaminación atmosférica, Cali, análisis geoestadístico.

I. INTRODUCCIÓN

La contaminación atmosférica urbana constituye un problema relevante de salud pública en ciudades latinoamericanas con procesos acelerados de crecimiento urbano, expansión vehicular y transformación del uso del suelo. En Santiago de Cali, la calidad del aire presenta una dinámica espacial compleja debido a la interacción entre fuentes móviles, zonas urbanizadas, corredores industriales cercanos como Acopí-Yumbo y condiciones geográficas particulares asociadas al valle del río Cauca y la proximidad de los Farallones.

Aunque la ciudad cuenta con una red de monitoreo terrestre administrada por el DAGMA, la cobertura espacial de las estaciones es limitada frente a la heterogeneidad territorial del municipio. Esta limitación dificulta representar de manera continua los gradientes de contaminantes atmosféricos y su relación con variables urbanas, ambientales y meteorológicas. Por esta razón, el proyecto propone integrar información de estaciones de calidad del aire, datos satelitales, variables de reanálisis climático y descriptores espaciales para construir una representación más amplia del comportamiento ambiental en Cali.

El satélite Sentinel-5P (TROPOMI) provee mediciones diarias de columnas troposféricas o totales para NO_2 , SO_2 y O_3 con resolución nativa aproximada de 3.5 x 5.5 km. Aunque esta escala es más gruesa que la exposición barrial, su revisita diaria permite construir modelos predictivos espacio-temporales que combinen la precisión puntual de DAGMA con la cobertura espacial continua del satélite.

I-A. Contribuciones

Este trabajo aporta:

1. Un panel multifuente 2020-2024 con evidencia de 108.153 GB en el manifest global y 93.1 GB de escenas Sentinel-2 L2A crudas; de este panel se derivó un dataset curado de 1500 pares imagen-texto Sentinel-2 (12 bandas, 64×64) con etiquetas pseudo-supervisadas de Sentinel-5P y una versión model_safe sin concentraciones S5P como entradas directas.
2. Un modelo CLIP basado en RemoteCLIP ViT-B/32 con k -sparse Sparse Autoencoders v10/v5b, alcanzando Recall@1 = 0.6043 (test) y sparsity = 0.8809 con MSE de reconstrucción de validación = 0.0106.
3. Caracterización factorial completa (AFE con rotación Varimax y AFC con semopy) sobre los embeddings visuales, identificando cuatro constructos teóricos (Carga Antropogénica, Estrés Vegetal, Densidad Urbana, Volatilidad Atmosférica) con CFI = 0.9465 y RMSEA = 0.0312.
4. Pipeline predictivo ConvLSTM bidireccional + ST-Kriging residual sobre tensores $119 \times 8 \times 273 \times 48 \times 40$, con LOO-CV espacial para SO_2/O_3 , postproceso físico, mapas de incertidumbre, Moran/LISA y K-Means de perfiles críticos.
5. Despliegue end-to-end en producción: backend FastAPI con Dockerfile multi-stage, 26 pruebas unitarias pytest, y frontend React+Vite+Leaflet+TypeScript, ambos hospedados en HuggingFace Spaces con URLs públicas.

I-B. Organización del documento

La Sección II describe la Situación 1: construcción del panel, arquitectura cloud, manifests, EDA y costos. La Sección III integra la Situación 2 completa: GeoVision-CLIP, Sparse

Autoencoders y validación AFE/AFC sobre embeddings visuales, tal como lo exige la rúbrica. La Sección IV corresponde a la Situación 3: articulación del aprendizaje profundo con estadística geoestadística espacio-temporal mediante ConvLSTM, variogramas, ST-Kriging, Moran/LISA y validación espacial. La Sección V presenta el despliegue (backend, frontend, Docker, tests). La Sección VI resume los KPIs cumplidos contra la rúbrica oficial. La Sección VII discute limitaciones y trabajo futuro. La Sección VIII concluye. Los Apéndices A–D contienen especificaciones extendidas, hashes verificables y configuración de reproducibilidad.

II. TRABAJOS RELACIONADOS

II-A. Estimación satelital de calidad del aire en ciudades latinoamericanas

La estimación de contaminantes atmosféricos mediante sensores remotos en ciudades de América Latina ha sido objeto de estudio desde el lanzamiento de TROPOMI [2] en 2017. Trabajos previos en Bogotá [11] establecen el modelo de referencia para correlacionar columnas troposféricas con mediciones in-situ DAGMA-equivalentes, reportando coeficientes de correlación Pearson entre 0.55 y 0.78 para NO₂ urbano, dependientes de la temporalidad y la densidad de la red de monitoreo. En Cali, el problema es agravado por la topografía particular (valle del río Cauca con Farallones al oeste) y la heterogeneidad de fuentes (corredor industrial Yumbo al norte vs zonas residenciales al sur), que generan gradientes espaciales pronunciados no capturables con la red de 9 estaciones DAGMA actual.

II-B. Modelos contrastivos visual-textuales en teledetección

CLIP (Contrastive Language-Image Pre-training) ha sido adaptado al dominio de teledetección en múltiples trabajos. RemoteCLIP [1] re-entrena CLIP sobre 165K imágenes aéreas y satelitales con *captions* estructurados, alcanzando estado del arte en *zero-shot* clasificación de uso del suelo. Para tareas predictivas que requieren mayor interpretabilidad, los Sparse Autoencoders [9] fueron propuestos por Anthropic como herramienta para descomponer representaciones densas en *features* interpretables individualmente. La combinación **CLIP + k-sparse SAE + ensamble por semillas**, utilizada en GeoVision-CLIP, está poco documentada en el dominio específico de contaminación atmosférica urbana.

II-C. Geoestadística espacial y espacio-temporal

El índice de Moran I [7] es la métrica estándar de autocorrelación espacial global desde 1950, complementado por el análisis LISA local de Anselin [8] para identificar clústeres significativos. La librería PySAL [3] provee implementaciones eficientes con tests permutacionales. Para interpolación espacio-temporal, ST-Kriging modela la estructura residual en espacio y tiempo y permite corregir predicciones de aprendizaje profundo con una estimación explícita de incertidumbre. En este trabajo se usa PyKriging.OrdinaryKriging3D sobre residuos ConvLSTM y se evalúa si los residuos remanentes se aproximan a un comportamiento tipo *nugget* puro mediante variogramas experimentales.

II-D. Análisis Factorial Confirmatorio sobre embeddings

El uso de análisis factorial confirmatorio (AFC) sobre embeddings de redes neuronales es menos común que sobre indicadores clásicos. La librería *semopy* [5] de Igolkina y Meshcheryakov, escrita en Python puro, permite especificar modelos con sintaxis *lavaan* (R) y ajustar con ML, GLS o WLS. La búsqueda controlada sobre 10000 combinaciones de indicadores que se realiza en este trabajo es novedosa para embeddings CLIP de 512 dimensiones reducidos a 39 factores rotados.

III. SITUACIÓN 1: PANEL ESPACIO-TEMPORAL Y ARQUITECTURA CLOUD

La Situación 1 exige un panel longitudinal de mínimo 50 GB que integre imágenes satelitales, covariables meteorológicas, aerosoles y mediciones in-situ para Santiago de Cali. En este proyecto el umbral de volumen se verifica sobre la ingesta cruda/cache de datos, no sobre el panel analítico final, porque el panel final se almacena en Parquet comprimido y contiene variables agregadas por estación, fecha y grilla. La evidencia principal es el manifest global `manifest/manifest.json`, que registra 74.439 archivos y 108.153 GB, y el manifest Sentinel-2 raw `Entrega_Final/Situacion1/evidencias/manifests/scene_manifest.jsonl`, que registra 198 escenas L2A de 12 bandas con 93.1 GB decimales (86.7 GiB).

III-A. Arquitectura cloud y almacenamiento

La arquitectura de ejecución se implementó en RunPod con una GPU RTX 3090, 32 vCPU AMD EPYC 7C13, 125 GB de RAM y un volumen persistente de 180 GB. La decisión de separar el pod de cómputo del volumen persistente fue central: el pod podía reiniciarse o apagarse sin perder las descargas crudas, caches intermedios, manifests, paneles Parquet ni evidencias visuales. La persistencia también permitió auditar el proceso mediante hashes MD5 y publicar artefactos consolidados en Hugging Face Datasets.

El flujo de datos fue: fuentes externas (GEE, Copernicus/CDSE, NASA Earthdata, Copernicus CDS y SISAIRE/-DAGMA) → RunPod → volumen persistente → conversión Parquet/Zarr → manifests MD5 → EDA consolidado → panel `model_safe`. La separación entre cómputo efímero y almacenamiento persistente fue necesaria para evitar pérdida de datos durante reinicios del pod y para conservar artefactos intermedios auditables.

III-B. Fuentes integradas

La integración combinó fuentes satelitales, meteorológicas e in-situ. Cada fuente cumple una función distinta dentro del panel: Sentinel-5P aporta variables atmosféricas de columna, Sentinel-2 representa heterogeneidad urbana y cobertura superficial, ERA5-Land aporta condiciones meteorológicas horarias, MODIS MAIAC agrega información de aerosoles y DAGMA/SISAIRE funciona como referencia in-situ para contaminantes medidos en estaciones terrestres.

GeoVision-CLIP Cali - Situación 1




Figura 1: Arquitectura cloud de la Situación 1. El flujo integra fuentes satelitales e in-situ, cómputo en RunPod, almacenamiento persistente, procesamiento ETL, versionamiento remoto en Hugging Face Datasets y generación de artefactos para el informe en LaTeX.

Cuadro I: Fuentes obligatorias integradas para Situación 1.

Fuente	Variable principal	Periodo / resolución	Evidencia
Sentinel-5P	NO ₂ , SO ₂ , O ₃ columnas	2020-01-01 a 2024-12-31; diaria	manifest_sentinel5p_panel_cali_2020_2024.json
Sentinel-2 L2A	12 bandas ópticas + índices S2	2020-01-02 a 2024-12-16; 10/20/60 m	manifest_sentinel2_with_scl.json, scene_manifest.jsonl
ERA5-Land	temperatura, humedad, viento, presión	43.848 horas; 2020-2024	manifest_era5_modis.json
MODIS MAIAC	AOD 0.47 y 0.55 μm	1.827 días; 58.0 % observado	manifest_era5_modis.json
DAGMA/SISAIRE	NO ₂ , SO ₂ , O ₃ in-situ	803.146 registros largos	manifest_dagma_sisaire_2020_2024.json





Figura 2: Cobertura espacial de las fuentes integradas en la Situación 1. La figura permite verificar el bbox Cali, la grilla satelital y las estaciones DAGMA/SISAIRE usadas como referencia in-situ.

III-C. Sentinel-5P TROPOMI

Sentinel-5P se usó para columnas troposféricas o totales de NO₂, SO₂ y O₃, consultadas mediante Google Earth Engine a partir de las colecciones COPERNICUS/S5P/OFFL/L3_NO2, COPERNICUS/S5P/OFFL/L3_SO2 y COPERNICUS/S5P/OFFL/L3_O3. El sensor TROPOMI tiene resolución nativa aproximada de 3.5 x 5.5 km; para el panel se trabajó sobre el bbox oficial Cali[-76.60, 3.30, -76.40, 3.55] y se conservaron columnas de calidad s5p_qa_no2, s5p_qa_so2 y s5p_qa_o3. El panel tabular derivado contiene 1.270.896 filas, 19 columnas, 1.826 días únicos y los campos s5p_no2_column, s5p_so2_column y s5p_o3_column; su manifest reporta MD5 1523ff7952ed9ad7e76e4fa7e9c8f091 para el Parquet procesado.



(a) Columna Sentinel-5P NO₂.

Figura 3: Previsualización espacial de productos Sentinel-5P sobre el bbox Cali. Estas figuras permiten verificar que las columnas atmosféricas procesadas tienen cobertura espacial válida y estructura interpretable antes de integrarse al panel horario.

III-D. Sentinel-2 L2A

Sentinel-2 L2A aportó covariables ópticas de alta resolución. La ingesta cruda auditada contiene 198 escenas sobre los tiles MGRS 18NUJ y 18NUK, 12 bandas por escena, periodo 2020-01-02 a 2024-12-16 y 93.1 GB decimales. Esta evidencia supera el umbral de 50 GB de la rúbrica aun sin sumar Sentinel-5P, ERA5-Land, MODIS ni DAGMA. Para el panel tabular se derivaron 226.352 registros y 45 columnas con medias/desviaciones por banda, NDVI, BSI, NDBI, índice urbano, fracción de vegetación, nubosidad, porcentaje de píxeles válidos y distancia temporal a la observación óptica más cercana. El producto con métricas SCL añade porcentajes por clase de escena y recomienda filtrar con $s2_scl_cloud_pct \leq 30$ o $s2_scl_bad_pixel_pct \leq 30$ según el nivel de calidad requerido.

La evidencia visual de Sentinel-2 cumple dos propósitos: primero, verificar que las escenas tienen cobertura espacial válida sobre el área de estudio; segundo, confirmar que las bandas e índices derivados, como NDVI, producen covariables interpretables para representar vegetación, suelo y estructura urbana.

III-E. DAGMA/SISAIRE


El ground truth in-situ se construyó a partir de DAGMA/SISAIRE para NO₂, SO₂ y O₃ en nueve estaciones de Cali: Base Aérea, Canavalejo, Compartir, ERA - Obrero, Ermita, Flora, Pance, Transitoria - Navarro y Univalle. El proceso de limpieza eliminó registros de Yumbo, la estación Cascajal, contaminantes fuera del alcance y valores negativos; la deduplicación

priorizó SVCASC sobre API y SISAIRE. El resultado contiene 803.146 observaciones en formato largo y 278.618 filas en formato ancho horario. El archivo Parquet ancho está documentado en `manifest_dagma_sisaire_2020_2024.json` con MD5 `bedfacc54db156c24d2e209d4d7305d5`.

La información de DAGMA/SISAIRE es central porque permite conectar las fuentes satelitales y meteorológicas con mediciones terrestres. Sin embargo, su cobertura espacial está limitada al número de estaciones disponibles; por esta razón, el proyecto no depende exclusivamente de la red in-situ, sino que la complementa con Sentinel-5P, Sentinel-2, ERA5-Land y MODIS.

III-F. ERA5-Land y MODIS MAIAC

ERA5-Land aportó meteorología horaria agregada al bbox Cali: temperatura a 2 m, punto de rocío, humedad relativa, viento u/v a 10 m, velocidad y dirección del viento, presión superficial, precipitación y radiación solar descendente. El panel contiene 43.848 horas entre 2020-01-01 00:00 y 2024-12-31 23:00. MODIS MAIAC MCD19A2 aportó AOD en 0.47 y 0.55 μm , con 1.827 días, 1.060 días observados y 767 días interpolados o sin observación directa por nubosidad/cobertura. Ambos productos están documentados en `manifest_era5_modis.json`; el Parquet ERA5-Land tiene MD5 `99b089fa996344dc1dc6da336fc0cc93` y el Parquet MODIS tiene MD5 `1f634c08b19c0660543c98be1f198722`.



(a) Previsualización mosaico de **Sentinel-2**.

Figura 4: Evidencia visual de Sentinel-2 L2A. La banda original permite verificar cobertura y valores válidos, mientras que el NDVI resume información de vegetación usada posteriormente como covariable del panel.




Figura 5: Previsualización espacial MODIS MAIAC AOD sobre el bbox Cali. La figura permite verificar cobertura, valores válidos y estructura espacial de aerosoles antes de integrar la variable al panel.

ERA5-Land y MODIS cumplen un papel complementario. ERA5-Land aporta variables meteorológicas que explican transporte, dispersión y acumulación de contaminantes; MODIS MAIAC incorpora información de aerosoles, *útil* para caracterizar carga atmosférica y variabilidad ambiental.

III-G. Panel final y garantía anti-filtración

El panel integrado final se construyó a granularidad estación-hora. La versión completa conserva columnas Sentinel-5P directas para trazabilidad, pero la versión de modelado `model_safe` excluye `s5p_no2_column`, `s5p_so2_column` y `s5p_o3_column` para evitar *data leakage*. El archivo `panel_tabular/panel_geovision_cali_station_hourly_2020_2024_model_safe.parquet` contiene 278.618 filas, 102 columnas, nueve estaciones, cobertura temporal 2020-01-01 a 2024-12-31, 278.452 filas con unión Sentinel-5P y 269.609 filas con emparejamiento Sentinel-2 dentro de una ventana máxima de 30 días. Su MD5 es 617962658552dec5c9e3bce6ef69bd1b.

Esta decisión separa dos usos de Sentinel-5P: como pseudo-etiqueta y metadato de supervisión para construir clases/targets, y como variable prohibida de entrada directa durante entrenamiento o predicción. Por tanto, el panel cumple la restricción que penaliza el uso directo de concentraciones Sentinel-5P como entrada del modelo.

III-H. Análisis Exploratorio de Datos (EDA)

El EDA consolidado está en `Entrega_Final/Situacion1/EDA_consolidado_situacion1.ipynb` y exporta figuras a `figures/`. Se generaron más de ocho visualizaciones exigidas por la rúbrica, incluyendo mapa de estaciones DAGMA, cobertura espacial de fuentes, disponibilidad mensual por fuente, series diarias Sentinel-5P, series de

calidad Sentinel-2, histogramas AOD MODIS, series meteorológicas ERA5-Land, nulos por variable, cobertura del panel final y matriz de correlación entre contaminantes y covariables.

Cuadro II: Resumen estadístico del panel maestro horario DAGMA 2020-2024.

Contam.	Media	Mediana	P95
NO ₂ (µg/m ³)	14.06	12.15	33.25
SO ₂ (µg/m ³)	5.86	2.85	16.73
O ₃ (µg/m ³)	28.55	14.91	98.13

Los resultados exploratorios muestran tres patrones relevantes para el resto del proyecto. Primero, DAGMA/SISAIRE provee alta resolución temporal pero baja densidad espacial, por lo que no basta para interpolar toda la ciudad sin apoyo satelital. La cobertura observada es desigual: NO₂ 9.42 %, SO₂ 47.53 % y O₃ 68.64 %, lo que explica la limitación posterior de NO₂ en LOO-CV espacial. Segundo, Sentinel-2 aporta heterogeneidad intraurbana mediante índices de vegetación, suelo expuesto y urbanización, pero está limitado por nubosidad y periodicidad orbital. Tercero, Sentinel-5P y MODIS agregan continuidad temporal atmosférica, aunque con resolución espacial más gruesa que la escala barrial; esto justifica la fusión multifuente y el posterior uso de modelos espacio-temporales.

III-I. Evidencia visual de datasets

Las figuras anteriores complementan los manifests MD5 y los archivos Parquet generados durante la ingesta. Mientras los hashes permiten verificar integridad y trazabilidad de los artefactos, las previsualizaciones espaciales permiten auditar que cada fuente corresponde efectivamente al bbox Cali, que las variables procesadas tienen orientación espacial coherente y que existen patrones físicos interpretables antes de ser incorporados al panel de modelado.

En conjunto, la evidencia visual confirma tres aspectos: primero, la cobertura espacial de las fuentes satelitales e in-situ; segundo, la disponibilidad de campos atmosféricos Sentinel-5P para NO₂, SO₂ y O₃; y tercero, la existencia de covariables ópticas y de aerosoles derivadas de Sentinel-2 y MODIS MAIAC.

III-J. Costos y cuellos de botella

El volumen persistente RunPod de 180 GB tuvo un costo mensual reportado de USD 12.60. El pod GPU costó USD 0.46/h y el almacenamiento de contenedor 20 GB costó USD 0.003/h. Para una ventana operativa de 104 horas, el costo de cómputo fue aproximadamente USD 48.15, separado del costo mensual del volumen persistente. Los principales cuellos de botella fueron el peso de escenas Sentinel-2 multibanda, la duplicación temporal entre crudos, caches Zarr y Parquet derivados, y la necesidad de auditar manifests antes de eliminar datos pesados para liberar espacio.

III-K. Las cinco clases del CLIP

El dataset CLIP utiliza las cinco clases exactas exigidas por la rúbrica:

- contaminacion_alta_NO2
- contaminacion_alta_SO2
- ozono_anomalo
- vegetacion_densa
- suelo_urbano

La asignación de clase se realiza por percentiles temporales (p25, p50, p75, p90, p99) de las concentraciones S5P co-localizadas en cada tile S2.

IV. SITUACIÓN 2: GEOVISION-CLIP, SPARSE AUTOENCODERS Y VALIDACIÓN AFE/AFC

En este bloque se agrupan tres componentes evaluados de forma conjunta: (i) construcción del dataset imagen–texto, (ii) entrenamiento contrastivo GeoVision-CLIP con Sparse Auto-encoders y (iii) validación psicométrica de los embeddings mediante AFE y AFC.

IV-A. Dataset imagen–texto y control de filtración

La Situación 2 parte de los tiles Sentinel-2 L2A generados en la Situación 1. La versión seleccionada es `outputs/clip_dataset_final_step_by_step/clip_s2_12band_pdf_classes_v5b_high_purity_1500_gsplits/`: contiene 1500 pares imagen–texto con split por grupo para reducir fuga espacial entre particiones. La partición final adoptada es **holdout por scene_id con tamaños 1000/265/235** (train/val/test), elegida sobre el split estratificado clásico 70/15/15 para evitar fuga entre escena y fecha; el dataset global conserva 300 pares por clase. Cada registro contiene un tile Sentinel-2 de tamaño 64 × 64 × 12 con bandas B01, B02, B03, B04, B05, B06, B07, B08, B8A, B09, B11 y B12; la banda B10 se excluye. Las máscaras SCL se conservan como control de calidad y no entran como canal visual del modelo.

La metadata final está en `outputs/clip_dataset_final_step_by_step/clip_s2_12band_pdf_classes_v5b_high_purity_1500_gsplits/metadata.jsonl`. Las cinco clases son `contaminacion_alta_NO2`, `contaminacion_alta_SO2`, `ozono_anomalo`, `vegetacion_densa` y `suelo_urbano`. Sentinel-5P se usa sólo como pseudo-etiqueta y metadato textual; no se incorpora como imagen, banda ni variable numérica directa de entrada.

Desde el punto de vista estadístico, esta separación evita una forma directa de *target leakage*: si las columnas S5P usadas para construir las clases entraran también como predictores, el modelo podría recuperar la etiqueta por correlación trivial y no por evidencia visual Sentinel-2. Por esta razón, el problema queda formulado como aprendizaje contrastivo entre patrones espectrales/espaciales de S2 y descripciones textuales derivadas de clases ambientales, no como regresión directa sobre contaminantes ya observados. El *split* por grupo refuerza esta decisión al reducir la probabilidad de que tiles espacialmente vecinos aparezcan simultáneamente en entrenamiento y prueba.

IV-B. Arquitectura

El modelo final recomendado se denomina RemoteCLIP ViT-B/32 + k-sparse SAE v10/v5b. Se compone de:

1. **Encoder visual:** RemoteCLIP ViT-B/32 (checkpoint oficial chendelong/RemoteCLIP, archivo RemoteCLIP-ViT-B-32.pt), cargado con `open_clip.create_model_and_transforms('ViT-B-32')` y `strict=True` (*All keys matched successfully*). Output: embedding visual de 512 dimensiones.
2. **Encoder textual:** Se empleo uno adecuado para captions en español y prompts de clase. El `paraphrase-multilingual-MiniLM-L12-v2`.
3. **Capa de fusión auxiliar:** concatenación/proyección de embeddings visuales, texto y covariables Sentinel-2 permitidas. Las variables auxiliares incluyen estadísticos espectrales, latitud, longitud y fecha; se excluyen concentraciones directas Sentinel-5P.
4. **Sparse Autoencoder (SAE) *k-sparse*:** autoencoder con activaciones ocultas top-*k* para inducir sparsity. La pérdida total combina InfoNCE para alineación contrastiva ($\alpha = 0,1$), error de reconstrucción MSE y regularización L1. El entrenamiento final usa `seed57_k12_drop25_wd1e3` con 90 epochs y batch size 64; el sweep evaluó 12 semillas reproducibles.

IV-C. Selección v10

Tras un *seed sweep* de 12 entrenamientos, se seleccionó `seed57_k12_drop25_wd1e3` por su mejor Recall@1 de test dentro de la familia v10. La evidencia está en `output_s/clip_training_remoteclip_fusion_ksae_v10_v5b_gssplit_seed_sweep/summary_remoteclip_fusion_ksae_v10_v5b_gssplit_seed_sweep.json` y el entrenamiento final con logging completo está en `outputs/clip_training_remoteclip_fusion_ksae_v10_v5b_gssplit_seed57_full_logging/manifest_training_final.json`.

- Checkpoint seleccionado: `seed57_k12_drop25_wd1e3_full_logging_best.pt`
- Mejor epoch: 31
- MD5 checkpoint: `461bd40ef53051c9b6fca15685fee3d5`

El modelo final no usa concentraciones Sentinel-5P como entradas directas. Las entradas permitidas son el tile Sentinel-2, estadísticos espectrales auxiliares, latitud, longitud y fecha.

La selección por *seed sweep* debe interpretarse como una evaluación de estabilidad frente a la inicialización, no como una prueba independiente adicional. Todos los candidatos comparten la misma familia de arquitectura y protocolo de partición; por tanto, el resultado seleccionado resume el mejor punto operativo dentro de una búsqueda controlada y reproducible. Esta lectura es importante porque el Recall@1 de un modelo contrastivo puede variar por la inicialización de

las capas de proyección y por el patrón de batches negativos, especialmente con 1500 pares y cinco clases semánticamente cercanas.

IV-D. Resultados

Cuadro III: Métricas finales de Situación 2 para RemoteCLIP + k-sparse SAE v10/v5b.

Métrica	Val	Test
Recall@1 image-to-text	0.5271	0.6043
Recall@5 image-to-text	1.0000	1.0000
SAE sparsity ratio	0.8809	0.8809
SAE reconstruction MSE	0.0106	0.0114
passes_both	true	

El KPI discriminativo principal es Recall@1, que supera el umbral ($\geq 0,45$) en test con 0.6043. La sparsity SAE (0.8809) supera el umbral de 0.70 y el MSE de reconstrucción de validación (0.0106) queda muy por debajo de 0.05; el MSE test adicional es 0.0114. La evidencia tabular está consolidada en `Entrega_Final/Situacion2/metricas/kpi_situacion2_summary.csv`.

La interpretación estadística de Recall@1 es directa: para cada imagen, el modelo ordena los textos candidatos por similitud en el espacio compartido y se considera acierto cuando el texto correcto queda en la primera posición. Un valor de 0.6043 indica que el primer vecino textual coincide con la clase esperada en 60.43 % de los casos de prueba, superando el azar de un problema balanceado de cinco clases (20 %) y el umbral operativo de la rúbrica con holgura amplia.

Las métricas del SAE muestran un compromiso favorable entre compresión interpretable y preservación de información. Una *sparsity ratio* de 0.8809 implica que la mayor parte de las unidades latentes permanece inactiva para cada observación, lo que favorece representaciones localizadas y más auditables. Al mismo tiempo, el MSE de reconstrucción de validación de 0.0106 indica que esta restricción de sparsity no destruye la geometría esencial del embedding. En conjunto, el SAE actúa como regularizador interpretativo: fuerza una codificación más selectiva sin sacrificar de forma relevante la reconstrucción del espacio latente.




Figura 6: Evolución de Recall@1 durante el entrenamiento instrumentado de la configuración v10/v5b. La curva se conserva como evidencia de entrenamiento; el KPI principal se reporta desde `sweep_best.pt`.

IV-E. Reproducibilidad y verificación de checkpoints

La entrega final preserva **dos checkpoints** de la misma configuración v10/v5b seed57: el `sweep_best.pt` se reporta como resultado principal con Recall@1 = 0.6043 en test, y el `full_logging_best.pt` corresponde al reentrenamiento instrumentado con curvas completas de *loss* y Recall@1 por época, obtenido sobre la misma configuración con Recall@1 = 0.5489 en test. Ambos superan el umbral mínimo de la rúbrica ($\geq 0,45$). Se conserva el reentrenamiento instrumentado porque la rúbrica solicita explícitamente curvas de entrenamiento.

Adicionalmente, el checkpoint final del ConvLSTM espacial covariado de la Situación 3 (`convlstm_covariates_spatial_best.pt`) también se verifica con `hashlib.md5` chunked.

Cuadro IV: Verificación MD5 de los checkpoints finales del proyecto.

Checkpoint	MD5
<code>sweep_best.pt</code> (CLIP+SAE principal)	2a512b70e4a837a0c652aa71f2c970b4
<code>full_logging_best.pt</code> (CLIP+SAE instrumentado)	461bd40ef53051c9b6fca15685fee3d5
<code>convlstm_covariates_spatial_best.pt</code> (ConvLSTM)	4be0b8360b37a6d30ed4c386c9c79d0d

IV-F. Aclaración metodológica sobre Recall@5

El dataset es evaluado contra cinco prompts de clase. Recall@5 = 1.0 contra cinco candidatos es cobertura de clases: al mirar el top-5 entran todos los prompts disponibles. Por tanto, no debe interpretarse como recuperación *pair-level* estricta ni como evidencia fuerte de ranking fino. Se reporta por transparencia y porque aparece en la rúbrica, pero la métrica de discriminación real es Recall@1.

En consecuencia, la evidencia de separabilidad se apoya principalmente en Recall@1 y *Macro Recall*. Recall@5 se mantiene como verificación de que el protocolo de evaluación no excluye clases candidatas, pero no permite distinguir entre un ranking excelente y uno apenas suficiente cuando el universo de candidatos tiene exactamente cinco elementos.

IV-G. Interpretabilidad SAE

La sparsity inducida por el SAE facilita identificar unidades latentes activas por clase y evita usar el embedding denso como una caja negra completamente opaca. Como evidencia complementaria, se generó un mapa de calor de unidades SAE por clase en `outputs/sae_analysis_v10_v5b_gsplits_seed57_full_logging/sae_top_units_by_class_heatmap.png`. Esta visualización no reemplaza las métricas de retrieval, pero ayuda a defender que las representaciones tienen estructura semántica separable entre contaminación, vegetación y suelo urbano.

La lectura del mapa de calor debe hacerse como análisis exploratorio de activaciones, no como prueba causal. Si ciertas unidades aparecen consistentemente entre las más activas para clases de contaminación o vegetación, ello sugiere que el modelo aprendió direcciones latentes asociadas con patrones visuales recurrentes. Sin embargo, la validez cuantitativa permanece anclada a las métricas de prueba y a la verificación posterior mediante AFE/AFC.




Figura 7: Unidades SAE más activas por clase. La figura resume interpretabilidad mecánica del espacio *k-sparse*.

IV-H. Validación AFE/AFC de los embeddings visuales

Se realizó AFE y AFC sobre los embeddings visuales `remoteclip_visual_512` extraídos desde `outputs/clip_training_remoteclip_v10_v5b_embeddings/embeddings_remoteclip_v10_v5b.npz`. La matriz analizada tiene forma 1500×512 y proviene de tiles Sentinel-2 L2A, no de concentraciones Sentinel-5P. Por tanto, el análisis factorial valida la estructura del espacio visual latente sin introducir *leakage*. Los resultados reproducibles están en `outputs/pca_afe_afc_remoteclip_v10_v5b_desde_cero/`.

Este análisis responde una pregunta distinta al retrieval: no evalúa si el modelo clasifica correctamente, sino si el espacio visual aprendido contiene dimensiones correlacionadas que puedan resumirse mediante constructos latentes interpretables. La matriz 1500×512 ofrece una relación observaciones/dimensiones suficiente para una exploración inicial, pero sigue siendo de alta dimensionalidad; por ello se estandariza y se reduce antes de estimar factores rotados y modelos confirmatorios.

IV-H1. AFE – PCA con rotación Varimax:

Se aplicó `StandardScaler`, PCA completo (`sklearn.decomposition.PCA`) y rotación Varimax. Se retuvieron los componentes necesarios para alcanzar varianza acumulada $\geq 80\%$. La evidencia principal

está en 01_afe_cargas_rotadas_varimax_remotecclip_v10_v5b.csv, 03_factor_scores_remotecclip_v10_v5b.parquet y 09_manifest_pca_afe_afc_v10_v5b.json.

La estandarización evita que dimensiones con mayor escala numérica dominen artificialmente la descomposición. PCA se usa como etapa de reducción estable para condensar la varianza del embedding antes de la rotación; Varimax, por su parte, busca una estructura más simple al concentrar cargas altas en menos factores. Que 39 componentes expliquen 0.8013 de la varianza implica una compresión de 512 dimensiones a 39 ejes principales reteniendo más del 80 % de la información lineal, lo cual respalda que el embedding no es ruido isotrópico sino un espacio con estructura estadística aprovechable.

Cuadro V: Resultados AFE sobre embeddings RemoteCLIP.

Métrica	Valor
Dimensión original	512
Observaciones analizadas	1500
Componentes para varianza $\geq$ 80 %	39
Varianza acumulada alcanzada	0.8013
Rotación aplicada	Varimax ($\gamma = 1,0$)

IV-H2. AFC – Modelo de cuatro constructos: Se especificó un modelo de análisis factorial confirmatorio con `semopy` usando cuatro constructos latentes (Carga Antropogénica, Estrés Vegetal, Densidad Urbana, Volatilidad Atmosférica), cada uno con dos indicadores derivados de los factores AFE de mayor capacidad discriminativa por clase. La selección se realizó mediante búsqueda controlada de 10000 modelos candidatos, registrada en 05_búsqueda_afc_modelos.csv y 09_manifest_pca_afe_afc_v10_v5b.json:

El paso confirmatorio impone una hipótesis más restrictiva que el AFE: las relaciones entre factores observados y constructos latentes se fijan antes de evaluar el ajuste global. Por ello, el AFC no debe leerse como una nueva optimización del clasificador, sino como una prueba de plausibilidad estructural sobre los factores derivados del embedding visual. Los cuatro constructos se eligieron porque corresponden a mecanismos ambientales interpretables y porque permiten contrastar si las dimensiones latentes separan fuentes antropogénicas, vegetación, urbanización y variabilidad atmosférica.

El modelo AFC v10_v5b especifica cuatro constructos latentes con dos indicadores cada uno (syntax `lavaan`): *Carga Antropogenica* con Factor_1 + Factor_29; *Estrés Vegetal* con Factor_6 + Factor_27; *Densidad Urbana* con Factor_2 + Factor_5; y *Volatilidad Atmosférica* con Factor_16 + Factor_9.

IV-H3. Discusión de índices de ajuste: El modelo AFC alcanza un ajuste satisfactorio frente a los KPIs: **CFI = 0.9465 > 0.90** y **RMSEA = 0.0312 < 0.08**. En particular, el RMSEA bajo evidencia un error de aproximación mínimo entre la matriz de covarianzas implicada por el modelo y la observada, mientras que el CFI por encima del umbral requerido confirma que la estructura factorial es estadísticamente aceptable para representar relaciones latentes en embeddings visuales.

Cuadro VI: Índices de ajuste del modelo AFC final (v10_v5b).

Índice	Valor	Umbral	Cumple
CFI	0.9465	> 0.90	Sí
RMSEA	0.0312	< 0.08	Sí
SRMR	0.1458	< 0.10	ver disc.
χ^2	34.49	—	inform.
DoF	14	—	—
χ^2 / DoF	2.46	< 3	Sí
Modelos evaluados	10000	—	exhaust.

El CFI compara el modelo propuesto contra un modelo nulo de independencia; por tanto, un valor de 0.9465 indica una mejora sustancial frente a asumir ausencia de estructura entre indicadores. El RMSEA evalúa el error de aproximación por grado de libertad; un valor de 0.0312 sugiere que la discrepancia residual es baja para la complejidad del modelo. La razón $\chi^2/\text{DoF} = 2.46$ también queda dentro del rango usualmente aceptable (< 3), reforzando que el ajuste no depende de un solo índice.

El SRMR = 0.1458 supera el umbral deseable de 0.10. Esta limitación es esperable en un AFC compacto de dos indicadores por constructo y debe interpretarse como evidencia de que el modelo cumple los umbrales exigidos (CFI/RMSEA), pero no como una validación psicométrica exhaustiva. La evidencia computacional de los índices está en `outputs/pca_afe_afc_remotecclip_v10_v5b_desde_cero/07_check_final_pdf.csv`.




Figura 8: Varianza acumulada del PCA sobre embeddings RemoteCLIP v10/v5b. La figura respalda la retención de 39 componentes para superar el 80 % de varianza explicada.




Figura 9: Scree plot de autovalores PCA para embeddings RemoteCLIP v10/v5b. Complementa la evidencia AFE al mostrar la caída progresiva de componentes principales.

V. SITUACIÓN 3: CONV LSTM, ST-KRIGING Y VALIDACIÓN GEOESTADÍSTICA ESPACIO-TEMPORAL

La Situación 3 corresponde al cierre predictivo y geoestadístico del proyecto. La versión final verificable se consolida en `Entrega\Final\Situacion3/notebooks/99\_consolidado\_situacion3\_rubrica.ipynb`, que integra cache Sentinel-2 en Zarr, embeddings GeoVision-CLIP/SAE, tensor espacial, ConvLSTM bidireccional, ST-Kriging de residuos, validación LOO-CV espacial, Moran/LISA, K-Means de perfiles críticos y mapas finales corregidos con restricciones físicas. La salida principal de KPI está en `Entrega\Final\Situacion3/outputs/metricas/kpi\_situacion3\_physical\_bounds\_summary.csv`.

V-A. Pipeline de Situación 3

El pipeline final parte de una secuencia temporal de 8 observaciones Sentinel-2 por celda, codificada con embeddings h_{256} de GeoVision-CLIP/SAE y covariables físicas adicionales. El tensor de entrada tiene forma $119 \times 8 \times 273 \times 48 \times 40$: 256 canales latentes más 17 covariables espectrales, de calidad SCL, espaciales y temporales. Los targets tienen forma $119 \times 3 \times 3 \times 48 \times 40$, correspondientes a tres contaminantes (NO_2 , SO_2 , O_3) y tres horizontes ($T+1$, $T+3$, $T+7$).

La arquitectura predictiva es una ConvLSTM bidireccional con `hidden=128`, kernel 3×3 , dos capas y salida $B \times 3 \times 3 \times H \times W$. El split temporal/espacial usado para entrenamiento fue 83 muestras de entrenamiento, 17 de validación y 19 de prueba. El mejor checkpoint se obtuvo en la época 9, con *val loss* escalada de 0.1429. Sobre el conjunto de prueba enmascarado, el modelo base obtiene $\text{RMSE} = 7.54$, $\text{MAE} = 5.46$ y $R^2 = 0.700$ sobre 501 targets observables.

La predicción ConvLSTM se corrige posteriormente con ST-Kriging de residuos. Para cada contaminante y horizonte se calculan residuos $e = y_{\text{obs}} - \hat{y}_{\text{ConvLSTM}}$ en estaciones DAGMA/SISAIRE y se interpola el campo residual con `PyKriging.OrdinaryKriging3D` sobre longitud, latitud y tiempo. El mapa final es:

$$\hat{y}_{\text{final}}(s, t) = \hat{y}_{\text{ConvLSTM}}(s, t) + \hat{e}_{\text{OK3D}}(s, t)$$

acompañado por la varianza de kriging como proxy de incertidumbre espacial.

V-B. ConvLSTM bidireccional y validación predictiva

La Tabla VII resume la evaluación del modelo ConvLSTM antes de la corrección geoestadística. Los resultados por contaminante muestran que SO_2 es el objetivo más estable, mientras que NO_2 tiene muy bajo soporte observacional en prueba ($n = 6$) y no admite una interpretación espacial robusta. Por horizonte, el desempeño se mantiene estable entre $T+1$ y $T+7$, sin degradación explosiva.

Cuadro VII: ConvLSTM bidireccional: métricas de prueba enmascaradas.

Scope	RMSE	MAE	R^2	n
Todos	7.54	5.46	0.700	501
SO_2	4.95	3.30	0.029	237
O_3	9.27	7.35	0.217	258
$T+1$	7.88	5.63	0.726	167
$T+3$	7.09	5.01	0.700	166
$T+7$	7.62	5.73	0.667	168

La validación operacional de rúbrica se realiza sobre LOO-CV espacial para los contaminantes evaluables. NO_2 sólo cuenta con una estación disponible, por lo que ocultarla en un esquema leave-one-station-out deja al kriging residual sin estaciones del mismo contaminante. Por transparencia, NO_2 se modela y se mapea, pero se marca como `no_evaluable` para LOO-CV espacial. SO_2 y O_3 sí se evalúan con LOO-CV real.

Cuadro VIII: LOO-CV espacial con ST-Kriging residual y postproceso físico.

Contam./horiz.	RMSE	MAE	R^2	Cob. 95 %
$\text{SO}_2 T+1$	3.895	2.447	0.790	0.945
$\text{SO}_2 T+3$	3.740	2.430	0.801	0.926
$\text{SO}_2 T+7$	3.831	2.422	0.806	0.942
$\text{O}_3 T+1$	8.515	6.412	0.448	0.940
$\text{O}_3 T+3$	7.348	5.764	0.527	0.939
$\text{O}_3 T+7$	7.881	6.162	0.492	0.939
$\text{SO}_2 + \text{O}_3$	6.382	4.424	0.807	0.939

El RMSE de $\text{SO}_2 T+1$ cumple el mínimo de rúbrica ($\leq 6 \text{ ug/m}^3$) con 3.895; $\text{O}_3 T+1$ cumple el mínimo ($\leq 12 \text{ ug/m}^3$) con 8.515. El R^2 promedio sobre contaminantes evaluables alcanza 0.807, clasificado como excelente frente al umbral de 0.75. La cobertura empírica del cinturón $\pm 1.96\sigma_{\text{kriging}}$ es 0.939, por encima del mínimo de 0.92.

V-B1. *Lectura estadística de los resultados LOO-CV*: La diferencia entre SO_2 y O_3 es metodológicamente relevante. SO_2 presenta errores absolutos menores y R^2 alrededor de 0.80 en los tres horizontes, lo que indica que el sistema captura de forma consistente la variabilidad observada en estaciones. Esto es compatible con un contaminante más localizado, donde la corrección residual por estaciones aporta información espacial concreta. O_3 , en cambio, obtiene RMSE más alto

y R^2 moderado (0.45–0.53), comportamiento esperable para un contaminante secundario fotoquímico con mezcla regional y dependencia de radiación, meteorología y precursores no completamente observados en el tensor.

El resultado agregado SO_2+O_3 no debe interpretarse como sustituto de los análisis por contaminante, sino como resumen operativo de los contaminantes evaluables. Su $R^2 = 0,807$ se calcula sobre 2651 predicciones LOO-CV, después del mismo postproceso físico usado para mapas y API. Esta consistencia entre validación y producto evita comparar métricas de un pipeline con salidas generadas por otro. En contraste, NO_2 se excluye del KPI espacial porque la evidencia observacional disponible no permite un esquema leave-one-station-out defendible: con una sola estación, el conjunto de entrenamiento residual quedaría vacío al ocultarla.

La cobertura 0.939 del cinturón $\pm 1,96\sigma_{kriging}$ indica que la incertidumbre de kriging está razonablemente calibrada para los contaminantes evaluables: aproximadamente 93.9 % de las observaciones LOO-CV caen dentro del intervalo empírico definido por la predicción corregida y la desviación asociada al kriging. El valor queda por encima del umbral mínimo de 92 %, aunque por debajo del criterio excelente de 95 %. Esto sugiere que la varianza espacial captura gran parte de la incertidumbre, pero todavía subestima algunos errores extremos, especialmente en presencia de episodios locales o datos de estación con outliers.

V-B2. Comparación ConvLSTM base vs. corrección ST-Kriging: La Tabla IX compara el desempeño antes y después de aplicar ST-Kriging residual y restricciones físicas. La corrección no se comporta como una mejora uniforme en todos los casos: para $\text{SO}_2\ T+1$ el RMSE aumenta ligeramente, mientras que para $\text{SO}_2\ T+3$, $\text{SO}_2\ T+7$ y los tres horizontes de O_3 disminuye. Esta lectura es importante porque evita presentar el kriging como una etapa mágica; su valor principal es combinar corrección local, superficie continua e incertidumbre, no optimizar siempre cada métrica puntual.

Cuadro IX: Comparación LOO-CV: ConvLSTM base vs. ST-Kriging residual corregido.

Caso	RMSE base	RMSE corr.	Δ RMSE	R^2 corr.
$\text{SO}_2\ T+1$	3.866	3.895	+0.029	0.790
$\text{SO}_2\ T+3$	3.846	3.740	-0.106	0.801
$\text{SO}_2\ T+7$	3.877	3.831	-0.046	0.806
$\text{O}_3\ T+1$	8.580	8.515	-0.065	0.448
$\text{O}_3\ T+3$	7.518	7.348	-0.170	0.527
$\text{O}_3\ T+7$	7.924	7.881	-0.043	0.492
SO_2+O_3	6.454	6.382	-0.072	0.807

El cambio agregado de RMSE es modesto (-0.072), pero positivo. La ganancia más clara aparece en R^2 agregado y en la cobertura probabilística del intervalo de kriging. Desde la perspectiva de producto, esto justifica mantener la etapa geoestadística: el usuario no recibe sólo una concentración puntual, sino también una medida espacial de incertidumbre que puede visualizarse como mapa de varianza. Además, el postproceso físico evita respuestas imposibles, como concentraciones ne-

gativas, sin ocultar que algunas correcciones locales pueden empeorar ligeramente el RMSE en casos particulares.

V-C. Postproceso físico y mapas finales

Los mapas corregidos aplican dos restricciones físicas: si la corrección ST-Kriging produce una concentración negativa, se usa como respaldo la predicción ConvLSTM; si esta también es negativa, se aplica piso cero. Además, la varianza de kriging se recorta a cero si el cálculo numérico produce valores negativos. Este postproceso eliminó 603 predicciones negativas y 10 varianzas negativas en los mapas finales, dejando 17280 filas sin concentraciones negativas.




Figura 10: Mapa final $\text{SO}_2\ T+1$ corregido por ST-Kriging residual y restricciones físicas.




Figura 11: Varianza de kriging asociada al mapa SO_2 $T + 1$, usada como proxy de incertidumbre espacial.




Figura 12: Mapa LISA local para SO_2 en horizonte $T + 7$. La figura muestra clústeres espaciales significativos y complementa el Moran I global.

V-D. Moran Global, LISA y K-Means sobre mapas finales

Se recalculó Moran I global sobre los 9 mapas finales (3 contaminantes $\times$ 3 horizontes) usando 1920 celdas de grilla, $k = 8$ vecinos y 999 permutaciones. Los 9 mapas son significativos con $p = 0,001$ y valores de Moran I entre 0.898 y 0.957, cumpliendo ampliamente el umbral de rúbrica ($I > 0,30$, $p < 0,05$).

Cuadro X: Moran I global sobre mapas finales corregidos.

Mapa	I	p_sim	z_sim	n
NO_2 $T + 1$	0.929	0.001	81.43	1920
NO_2 $T + 3$	0.957	0.001	86.35	1920
NO_2 $T + 7$	0.898	0.001	79.09	1920
SO_2 $T + 1$	0.913	0.001	80.43	1920
SO_2 $T + 3$	0.948	0.001	85.82	1920
SO_2 $T + 7$	0.930	0.001	83.48	1920
O_3 $T + 1$	0.919	0.001	79.98	1920
O_3 $T + 3$	0.925	0.001	85.37	1920
O_3 $T + 7$	0.918	0.001	81.23	1920

El análisis LISA local generó 10254 celdas-horizonte significativas con $\alpha = 0,05$, y K-Means identificó cinco perfiles espaciales críticos sobre los mapas corregidos. El cluster de mayor riesgo contiene 432 celdas, media de perfil 18.06, máximo 38.30 y centro aproximado en (3,487, -76,480), consistente con zonas urbanas/industriales de mayor exposición relativa.




Figura 13: K-Means de perfiles críticos sobre los 9 mapas finales corregidos.

V-E. Variogramas de residuos y limitaciones

Los variogramas experimentales se calcularon sobre residuos LOO corregidos físicamente. El KPI ideal exige residuos tipo nugget puro, es decir, ausencia de estructura espacial remanente. En la versión final, sólo 1 de 6 variogramas evaluables SO_2/O_3 queda clasificado como `sin_estructura_nugget_puro`; los otros 5 conservan

estructura residual detectable. Por tanto, este KPI se reporta honestamente como `no_cumple`, aunque el sistema sí cumple RMSE, R^2 , Moran I, cobertura de incertidumbre y estabilidad temporal.




Figura 14: Variograma experimental de residuos corregidos para $O_3 T+1$. Se incluye como ejemplo evaluable de diagnóstico residual; el resultado global permanece como `no_cumple` porque sólo 1 de 6 combinaciones SO_2/O_3 queda sin estructura espacial remanente.

La degradación de RMSE entre $T+1$ y $T+7$ es -1.64% sobre SO_2+O_3 , por debajo del umbral de aumento máximo de 60% . Esto indica que el horizonte $T+7$ no se deteriora frente a $T+1$ en la evaluación corregida, aunque debe interpretarse con cautela por el tamaño y composición de las estaciones disponibles. La API reporta una latencia de referencia medida al arranque sobre `/api/situacion3/radius`; en el despliegue público verificado fue 28.75 ms (mediana de 5 repeticiones), por debajo del umbral de 8 s.

VI. SITUACIÓN 4: FRONTEND, DESPLIEGUE Y PRODUCTO FINAL

La Situación 4 corresponde a la materialización del sistema como producto usable: API REST, frontend cartográfico, empaquetado Docker, pruebas automáticas y despliegue público. El objetivo no es introducir nuevas métricas de modelado, sino demostrar que las salidas de las situaciones anteriores pueden consultarse desde una interfaz reproducible, validada y accesible.

VI-A. Backend FastAPI

API REST v2.1 implementada con FastAPI 0.115 + Uvicorn + Pydantic v2. Expone tres grupos de endpoints:

- **Públicos (4):** GET `/`, GET `/health`, POST `/predict`, POST `/validate`.
- **Situación 3 (8):** bajo `/api/situacion3/`: metadata, mapa, punto, radio, clusters, LISA, KPIs y Moran.
- **Panel maestro DAGMA (3):** bajo `/api/panel/`: stations (las 9 estaciones reales de Cali con coordenadas y cobertura por gas), station/{name}/latest (última observación

horaria) y station/{name}/summary (estadísticas 2020-2024). Sirven el panel `panel_geovision_cali_station_hourly_2020_2024_model_safe.parquet` (278.618 filas, sin Yumbo).

La API no ejecuta RemoteCLIP, ConvLSTM ni PyKriging en cada request; sirve artefactos finales precomputados con saneamiento físico en tiempo de carga/respuesta.

La separación de responsabilidades del backend sigue una lógica simple: el cliente sólo envía coordenadas, contaminante, fecha y horizonte; la API valida dominio geográfico, normaliza la solicitud, calcula o recupera la predicción y devuelve un contrato JSON estable. Esto evita acoplar la interfaz a detalles internos del modelo, como nombres de checkpoints, tensores o rutas de artefactos. El endpoint `/validate` permite probar una coordenada antes de solicitar inferencia completa, reduciendo errores de usuario en el mapa.

El contrato de POST `/predict` acepta un JSON con lat, lon, pollutant ($NO_2/SO_2/O_3$), horizon_days (1, 3 o 7) y date; y responde con prediction ($\mu g/m^3$), uncertainty, unit, nearest_station y model_loaded. El contrato explicita la incertidumbre porque el producto no debe comunicar la predicción como un valor exacto. En el frontend se presenta como valor $\pm\sigma$, coherente con la Situación 3, donde la varianza de kriging se usa como proxy de incertidumbre espacial. En la ruta de Situación 3, las respuestas provienen de CSV/GeoJSON finales precomputados: mapas corregidos, varianzas, KMeans, LISA, Moran y KPIs físicos.

VI-B. Dockerfile multi-stage

Tanto backend como frontend usan Dockerfile multi-stage:

Backend: Stage 1 (*builder*) instala dependencias compiladas en venv aislado (`/opt/venv`); Stage 2 (*runtime*) copia sólo el venv, ejecuta como usuario no-root app, expone puerto 7860 (convención HuggingFace Spaces), incluye HEALTHCHECK y LABEL OCI.

Frontend: Stage 1 node:20-alpine ejecuta `npm ci` y `npm run build`; Stage 2 instala `serve` globalmente y sirve `dist/` en puerto 7860. Se optó por `serve` (de Vercel) en lugar de `vite preview` porque este último activa por defecto la protección `allowedHosts` contra DNS rebinding, lo cual rechaza requests provenientes del proxy de HuggingFace Spaces (HTTP 403 “host not allowed”).

VI-C. Suite de pruebas pytest

26 pruebas unitarias en `tests/test/_api.py` cubren: endpoints públicos (`/`, `/health`, `/predict`, `/validate`), invariantes físicas de salidas no negativas, los ocho endpoints `/api/situacion3/*` (mapas, radio, punto, clusters, LISA, KPIs, Moran) y los tres endpoints `/api/panel/*` (estaciones, ultima observación, resumen). Verifica además que el panel maestro tenga las 9 estaciones reales (sin Yumbo ni Acopi-Yumbo). Ejecución local verificada: 26 passed in 1.10 s.

Las pruebas no se limitan a verificar que el servidor responda: validan reglas de negocio relevantes para la r brica. En particular, las coordenadas fuera del bbox oficial de Cali deben rechazarse, los contaminantes soportados deben mantenerse dentro del alcance del proyecto, las salidas de concentraci n/varianza/sigma no deben ser negativas y los contratos consumidos por el frontend deben conservar estructura estable. Esto protege el despliegue contra regresiones cr ticas, por ejemplo aceptar una predicci n fuera del  rea de estudio, reintroducir valores f sicamente imposibles o romper el panel cartogr fico.

VI-D. Frontend React + Vite + Leaflet

Frontend SPA en TypeScript estricto. Una iteraci n previa ten a dos pesta as (“Mapa Situaci n 3” y “Consulta puntual”) pero se elimin  la segunda porque era redundante con el endpoint `/api/situacion3/point` y el selector de fecha resultaba no funcional fuera de las tres fechas reales (2024-12-17, 19, 23). La versi n final centra la experiencia en un  nico mapa Leaflet con las 9 estaciones DAGMA reales del panel maestro (Base A rea, Canaverelejo, Compartir, ERA-Obrero, Ermita, Flora, Pance, Transitoria-Navarro, Univalle), las 1920 celdas Sit3 en 4 capas alternables (Concentraci n, Incertidumbre, LISA, KMeans), slider de horizonte (T+1/T+3/T+7) que s  cambia visualmente el render, slider de radio (0.5-10 km), tooltips por celda con valor $\pm\sigma$, y bot nes de descarga CSV (mapa completo + resumen del  rea). Se agreg  tambi n un *toggle* de modo claro/oscuro persistido en `localStorage`, implementado con Tailwind `darkMode: class`.

La elecci n de React+Vite+Leaflet, en lugar de Streamlit o Gradio, responde a dos razones. Primero, la r brica penaliza interfaces no personalizadas, y una SPA permite controlar completamente interacci n cartogr fica, estado del formulario, render de resultados y descarga. Segundo, Leaflet es m s adecuado para representar estaciones, clicks geogr ficos, tooltips e integraci n futura de rasters de predicci n o varianza. Esta separaci n tambi n mejora mantenibilidad: el backend expone contratos HTTP y el frontend se limita a visualizaci n, validaci n de usuario y exportaci n.

Desde la perspectiva del usuario, el flujo operativo es: seleccionar fecha, horizonte y contaminante; hacer click dentro del bbox; recibir predicci n, incertidumbre y estaci n DAGMA m s cercana; y descargar el resultado como CSV. Este dise o conecta directamente los productos de modelado con una tarea de planeaci n ambiental: consultar zonas espec ficas de Cali sin abrir notebooks ni manipular archivos Parquet.

VI-E. Trazabilidad operacional de Situaci n 4

La Tabla XI resume c mo cada componente de producto se conecta con una evidencia verificable. Esta trazabilidad es importante porque el despliegue no se eval a s lo por estar publicado, sino por demostrar que sus piezas son reproducibles y auditables.

VI-E1. Bugs resueltos durante el deploy: El deploy a HuggingFace Spaces revel  cuatro bugs no detectados en el setup inicial: (1) directive `@ts-expect-error` innecesaria

Cuadro XI: Trazabilidad operacional de Situaci n 4.

Componente	Evidencia	Funci�n
FastAPI	<code>fastapi_app/main.py</code>	Contratos REST y validaci�n
Tests backend	<code>fastapi_app/tests/test_api.py</code>	Regresi�n funcional
Frontend	<code>geovision-frontend/</code>	Interfaz cartogr�fica
Backend Docker	<code>fastapi_app/Dockerfile</code>	Runtime reproducible
Frontend Docker	<code>geovision-frontend/Dockerfile</code>	Build est�tico reproducible
HF Spaces	URLs p�blicas	Acceso externo

rechazada por TS strict; (2) vite preview bloqueando hosts no-locales por protecci n DNS rebinding (resuelto cambiando a `serve`); (3) tiles Leaflet desordenados por timing del layout flex (resuelto con `map.invalidateSize()` en m ltiples temporizadores); y (4) Tailwind CSS *Preflight* aplicando `max-width: 100%` a todas las im genes, lo cual rompe los tiles 256 256 fijos de Leaflet (resuelto con override CSS espec fico `.leaflet-container img { max-width: none !important }`).

VI-F. Arquitectura de  mputo y costos

La infraestructura auditada para la construcci n del panel se ejecut  en RunPod con GPU RTX 3090, 32 vCPU AMD EPYC 7C13, 125 GB de RAM y un volumen persistente S3-compatible de 180 GB montado en `/workspace`. El costo operativo reportado para la ventana principal de procesamiento fue:

Cuadro XII: Costos reportados para infraestructura cloud de Situaci n 1.

Componente	Base de c�culo	USD
Pod RunPod GPU	104 h � 0.46 USD/h	47.84
Disco contenedor 20 GB	104 h � 0.003 USD/h	0.31
Volumen persistente 180 GB	mensual reportado	12.60
Hugging Face Datasets/Spaces	free tier	0.00
Google Earth Engine	uso acad�mico	0.00
Total ventana + storage	—	60.75

El costo de  mputo de la ventana fue USD 48.15 y el costo mensual del volumen persistente fue USD 12.60. La diferencia entre volumen bruto y panel comprimido fue el principal factor operativo: Sentinel-2 crudo super  por s  solo 93 GB, mientras que el panel `model_safe` final qued  en Parquet comprimido para an lisis y modelado.

VI-G. URLs en producci n

- Backend: <https://analiticalastdance-geovision-cali-api.hf.space>

- Frontend: <https://analiticalastdance-geovision-cali-frontend.hf.space>
- API Docs (Swagger): <https://analiticalastdance-geovision-cali-api.hf.space/docs>
- Dataset: <https://huggingface.co/datasets/analiticalastdance/geovision-cali>

VII. CUMPLIMIENTO DE LA RÚBRICA

La Tabla XIII consolida los KPIs cumplidos contra la rúbrica oficial del PDF.

VII-A. Caveats de rúbrica

La Situación 3 queda computacionalmente consolidada en el notebook final. Los caveats principales son: NO₂ no es evaluable con LOO-CV espacial por disponibilidad de una sola estación; y el KPI de variograma de residuos tipo nugget puro no se cumple porque 5 de 6 combinaciones SO₂/O₃ conservan estructura residual. La latencia de referencia del endpoint `/api/situacion3/radius` ya se mide al arranque y cumple ampliamente el umbral operativo.

VIII. DISCUSIÓN

VIII-A. Decisiones metodológicas defendibles

VIII-A1. ST-Kriging residual sobre ConvLSTM: La decisión de aplicar ST-Kriging sobre residuos, y no directamente sobre concentraciones, separa dos fuentes de información: la ConvLSTM aprende patrones espacio-temporales desde embeddings y covariables, mientras el kriging corrige sesgos locales observados en estaciones. Esta formulación evita que el interpolador sustituya al modelo profundo y permite reportar una varianza de kriging asociada a la corrección residual.

VIII-A2. NO₂ no evaluable por LOO-CV espacial: NO₂ se mantiene como salida del sistema y se generan mapas para $T + 1$, $T + 3$ y $T + 7$, pero no se reporta KPI LOO-CV espacial porque sólo hay una estación disponible para ese contaminante. Ocultar esa estación en leave-one-out dejaría cero estaciones de entrenamiento para el kriging residual, por lo que cualquier RMSE espacial sería metodológicamente indefendible.

VIII-A3. SRMR sobre el umbral deseable en AFC: El SRMR = 0.146 supera el umbral deseable de 0.10, aunque CFI y RMSEA cumplen los KPIs duros del PDF con margen amplio. En modelos con solo dos indicadores por constructo, SRMR penaliza desproporcionadamente la parsimonia. La rúbrica del PDF exige CFI >0.90 y RMSEA <0.08 explícitamente; ambos se cumplen.

VIII-A4. Variograma residual no completamente tipo nugget: El diagnóstico de residuos es deliberadamente estricto: exige que el error LOO-CV corregido no conserve estructura espacial detectable. La versión final cumple sólo 1 de 6 combinaciones evaluables, por lo que este KPI se marca como no cumplido. Esta limitación no invalida los RMSE ni el R^2 , pero sí indica que aún queda información espacial no capturada por ConvLSTM + ST-Kriging.

VIII-B. Limitaciones

VIII-B1. Artefactos precomputados en producción: El backend productivo de Situación 3 no ejecuta el pipeline pesado en cada request. Por diseño, carga artefactos finales precomputados (mapas corregidos, varianzas, LISA, KMeans, Moran y KPIs) y responde consultas espaciales sobre esos CSV/GeoJSON. Esto reduce latencia y evita depender de RemoteCLIP, ConvLSTM o PyKrige en tiempo de request, sin cambiar las métricas validadas offline.

VIII-B2. Latencia operativa: La API y el frontend están desplegados. La API mide al arranque la mediana de cinco llamadas al endpoint `/api/situacion3/radius`; en la verificación pública posterior al redeploy reportó 28.75 ms, por debajo del umbral de 8 s de la rúbrica. Esta cifra corresponde a consulta de artefactos precomputados, no a reejecución online de entrenamiento o kriging.

VIII-C. Trabajo futuro

1. Reentrenar o recalibrar el modelo con nuevas estaciones si se incorporan fuentes externas al panel actual.
2. Agregar exportación GeoTIFF además del CSV ya disponible en frontend.
3. Calcular Moran I dinámico (mensual o estacional) para capturar variabilidad intraanual (efecto pandemia 2020-2021, quemas agrícolas).
4. Variograma direccional (NE-SW vs NW-SE) para evaluar anisotropía por advección de viento.
5. Tests de carga del frontend con `locust` o `wrk` para verificar la latencia < 8 s exigida por el PDF.

IX. CONCLUSIONES

GeoVision-CLIP Cali demuestra la viabilidad de un sistema integral end-to-end que combina aprendizaje contrastivo visual-textual (CLIP+SAE), análisis factorial sobre embeddings, predicción ConvLSTM bidireccional, corrección ST-Kriging residual y despliegue completo en producción, aplicado al problema de estimación de contaminación atmosférica en Cali.

Los principales hallazgos son: (i) el modelo k-sparse SAE v10/v5b alcanza Recall@1 = 0.6043 con *sparsity* = 0.8809; (ii) los embeddings visuales admiten una factorización en cuatro constructos teóricos con CFI = 0.9465 y RMSEA = 0.0312; (iii) la etapa ConvLSTM + ST-Kriging cumple los RMSE mínimos para SO₂ y O₃, con R^2 promedio evaluable de 0.807 y cobertura 95 % de 0.939; y (iv) los 9 mapas finales muestran autocorrelación espacial significativa (Moran I ≥ 0.898 , $p = 0,001$). La limitación principal es NO₂, que se modela pero no admite LOO-CV espacial defendible por contar con una sola estación disponible.

Todo el sistema sigue principios estrictos de reproducibilidad (SEED = 42 universal, requirements pinneados, MD5 verificado en checkpoints) y está desplegado públicamente en HuggingFace Spaces con backend FastAPI y frontend React+Vite+Leaflet, ambos con sus respectivos Dockerfiles multi-stage y, para el backend, suite de pruebas `pytest` con 26/26 pasando.

Cuadro XIII: Cumplimiento de KPIs por componente de la rúbrica.

Sit.	KPI	Umbral PDF	Valor obtenido	Estado
1	Tamaño dataset	≥ 50 GB	108.153 GB global; 93.1 GB S2 raw	OK
1	Manifest MD5	válido	74.439 archivos con MD5	OK
1	EDA ≥ 8 visualizaciones	sí	40+ figuras exportadas	OK
1	Arquitectura cloud	sí	RunPod + volumen S3 + HF	OK
1	Costos y cuellos de botella	sí	USD 48.15 cómputo + USD 12.60/mes storage	OK
2	Recall@1 image-to-text (val)	≥ 0.45	0.5271	OK
2	Recall@1 image-to-text (test)	≥ 0.45	0.6043	OK
2	SAE sparsity ratio (test)	≥ 0.70	0.8809	OK
2	SAE recon MSE (val)	<0.05	0.0106	OK
2	passes_both flag	true	true	OK
2	S5P como input directo (<i>leakage</i>)	prohibido	solo pseudo-label	OK
2	5 clases exactas del PDF	obligatorio	cumplidas	OK
2	N pares CLIP	1000+	1500	OK
2	AFE varianza explicada	$\geq 80\%$	0.8013	OK
2	AFE rotación Varimax	aplicada	sí	OK
2	AFC 4 constructos	4	4	OK
2	AFC CFI	>0.90	0.9465	OK
2	AFC RMSEA	<0.08	0.0312	OK
2	AFC librería semopy	sí	sí	OK
2	Checkpoint MD5 verification	match 4/4	match 4/4	OK
3	RMSE LOO-CV SO ₂ $T+1$	≤ 6 ug/m ³	3.895	OK
3	RMSE LOO-CV O ₃ $T+1$	≤ 12 ug/m ³	8.515	OK
3	RMSE LOO-CV NO ₂ $T+1$	≤ 8 ug/m ³	no evaluable (n=1 est.)	Caveat
3	R^2 LOO-CV promedio evaluable	≥ 0.55	0.807	OK
3	Moran I predicciones	$> 0,30, p < 0,05$	min I=0.898; p=0.001	OK
3	Cobertura 95 % $\sigma_{kriging}$	$\geq 92\%$	0.939	OK
3	Degradación RMSE $T+1$ a $T+7$	$<60\%$ aumento	-1.64 %	OK
3	Variograma residuos nugget puro	sin estructura	1/6 sin estructura	No cumple
4	Backend FastAPI	sí	deployed HF Space	OK
4	Frontend React + Vite + Leaflet	sí	deployed HF Space	OK
4	9 estaciones DAGMA + click	sí	sí	OK
4	Slider T+1/T+3/T+7 + contaminantes	sí	sí	OK
4	Tooltips valor $\pm\sigma$ + CSV	sí	sí	OK
4	Dockerfile multi-stage backend	sí	sí (builder + runtime)	OK
4	Dockerfile multi-stage frontend	sí	sí	OK
4	Tests pytest	buena práctica	26/26 PASS	OK
4	URL pública	viva	2 URLs vivas	OK
4	Frontend NO Streamlit/Gradio	-30 % si falla	React + Vite	OK
4	Requirements pinneado	sí	versiones fijas ==	OK
4	Separación dev/prod	sí	2 requirements	OK
4	SEEDS reproducibles	sí	SEED=42 en todo	OK

REPOSITORIOS Y ENLACES

- Dataset y *analytics*: <https://huggingface.co/datasets/analyticalastdance/geovision-cali>
- Backend Space: <https://huggingface.co/spaces/analyticalastdance/geovision-cali-api>
- Frontend Space: <https://huggingface.co/spaces/analyticalastdance/geovision-cali-frontend>

AGRADECIMIENTOS

A los profesores Carlos Ferro y Cristian García, Universidad Autónoma de Occidente, por la guía y la rúbrica del proyecto.

APÉNDICE A

HASHES MD5 VERIFICABLES DE ARTEFACTOS CRÍTICOS

El hash MD5 del checkpoint seleccionado v10/v5b (Sección IV) fue verificado por re-cómputo *chunked* (bloques de 1 MB) y comparado contra el campo `checkpoint_best_md5` del

manifest final. Resultado: `md5_match = true`. El manifest global del proyecto (74.439 archivos, 108.15 GB) se generó con el mismo algoritmo y está publicado en `manifest/manifest.json` (30.5 MB).

Cuadro XIV: Hashes MD5 de artefactos principales del proyecto.

Artefacto	MD5
seed57_k12_best.pt	461bd40ef53051c9b6fca15685fee3d5
RemoteCLIP-ViT-B-32.pt	f99b4a164b93d5c1e9459960af5a9a11
metadata.jsonl (1500 pares v10/v5b)	be91fc65425e2181b1ddf6d91da878b6

El procedimiento de verificación es reproducible aplicando `hashlib.md5` en modo *chunked* (bloques de 1 MB) sobre

cada archivo y comparando contra el hash documentado en el manifest; esta estrategia permite validar archivos de varios GB sin cargarlos completamente en memoria.

APÉNDICE B

TABLA EXTENDIDA DE CARGAS FACTORIALES AFE

La rotación Varimax aplicada sobre los 39 componentes principales retenidos produce una matriz de cargas 512×39 . Para no duplicar tablas extensas ni introducir una lectura parcial de cargas, el cuerpo del reporte muestra la evidencia PCA/scree y este apéndice deja la trazabilidad completa: la matriz de cargas está disponible en `outputs/pca_afe_afc_remotecclip_v10_v5b_desde_cero/01_afe_cargas_rotadas_varimax_remotecclip_v10_v5b.csv`. La búsqueda controlada de 10000 modelos AFC se registra en `outputs/pca_afe_afc_remotecclip_v10_v5b_desde_cero/05_búsqueda_afc_modelos.csv`, con los índices de ajuste y asignaciones factoriales evaluadas.

APÉNDICE C

DIAGNÓSTICO DE VARIOGRAMA RESIDUAL

El diagnóstico final no usa NO_2 como evidencia de LOO-CV espacial porque sólo hay una estación disponible para ese contaminante. Para evitar mezclar una figura preliminar con el KPI evaluable, el cuerpo del reporte muestra un variograma residual de O_3 $T + 1$ y la matriz final reporta el estado agregado: 1 de 6 combinaciones SO_2/O_3 queda clasificada como `sin_estructura_nugget_puro`. Los artefactos reproducibles están en `Entrega\Final/Situacion 3/outputs/figuras/variograms/` y en `Entrega\Final/Situacion3/outputs/metricas/kpi\situacion3\_physical\_bounds\_summary.csv`.

APÉNDICE D

MATRIZ DE TRAZABILIDAD DE ARTEFACTOS

La Tabla [XV](#) consolida las rutas usadas como evidencia primaria por situación. Su propósito es hacer auditable el reporte: cada métrica relevante debe poder rastrearse a un notebook, manifest, CSV, JSON, checkpoint o figura generado por el pipeline. Esta matriz también ayuda a distinguir entre resultados de entrenamiento, validación, despliegue y documentación.

Esta trazabilidad permite reproducir selectivamente cada bloque sin volver a ejecutar todo el proyecto. Por ejemplo, si el evaluador desea validar Situación 2, basta con revisar el manifest de entrenamiento final, el resumen del *seed sweep* y el manifest AFE/AFC. Para Situación 3, el notebook 99 consolida el estado final y referencia los CSV/JSON usados en las tablas de KPI. Para Situación 4, el contrato observable es la API desplegada, pero la reproducibilidad se apoya en los Dockerfiles, requirements y pruebas unitarias.

APÉNDICE E

AMENAZAS A LA VALIDEZ

E-A. Validez interna

La amenaza principal de validez interna en Situación 2 es el *leakage*: las mismas columnas Sentinel-5P que generan

pseudo-etiquetas no pueden usarse como entradas directas. El reporte mitiga este riesgo usando una versión `model_safe`, describiendo el rol de S5P como pseudo-label y verificando que AFE/AFC se realiza sobre embeddings visuales Sentinel-2. En Situación 3, la amenaza interna más importante es mezclar validación y postproceso de forma inconsistente; por eso las métricas LOO-CV se reportan con la misma regla física usada para mapas finales.

E-B. Validez de medición

Las fuentes no miden exactamente la misma magnitud: Sentinel-5P observa columnas atmosféricas, DAGMA/SISAI-RE mide concentración cerca de superficie, Sentinel-2 describe superficie urbana y vegetación, ERA5-Land resume meteorología y MODIS aporta aerosoles. El proyecto no afirma equivalencia directa entre estas mediciones; las usa como vistas complementarias del proceso ambiental. Esta diferencia explica por qué algunos resultados, especialmente NO_2 , deben interpretarse con cautela cuando la red terrestre disponible es escasa.

E-C. Validez externa

El sistema está calibrado para Cali y su bbox oficial. Generalizar a otra ciudad exigiría reentrenar o al menos recalibrar pseudo-etiquetas, estaciones, covariables, distribuciones de uso del suelo y patrones meteorológicos. Las conclusiones son fuertes para el caso de estudio, pero no deben extrapolarse automáticamente a ciudades con topografía, red de monitoreo o mezcla de fuentes distinta.

E-D. Validez operacional

El despliegue demuestra integración de producto con artefactos finales precomputados: el backend no recalcula embeddings, ConvLSTM ni ST-Kriging en cada request, sino que sirve las salidas validadas de Situación 3 con saneamiento físico. Por tanto, la Situación 4 valida arquitectura, contrato, interacción, reproducibilidad del servicio y consulta de los productos finales. La latencia medida en `/api/situacion3/radius` cumple el umbral operativo reportado.

APÉNDICE F

CONFIGURACIÓN DE REPRODUCIBILIDAD

F-A. Variables aleatorias controladas

`SEED = 42` se fija universalmente en cada notebook mediante una función `set_global_seed(seed=42)` que inicializa el seed de `PYTHONHASHSEED`, `random`, `numpy`, `torch` (incluyendo `cuda.manual_seed_all`), y activa `torch.backends.cudnn.deterministic = True` con `benchmark = False` para garantizar reproducibilidad bit-a-bit en el entrenamiento.

Adicionalmente, los *splits* train/val/test del dataset CLIP usan `GroupShuffleSplit` con `random_state=42` agrupando por `tile_group_id` para evitar fuga de información espacial entre splits.

Cuadro XV: Trazabilidad de artefactos principales por situación.

Sit.	Artefacto	Ruta	Uso en reporte
1	Manifest global	manifest/manifest.json	74.439 archivos, 108.153 GB
1	Sentinel-2 raw	Entrega\Final/Situacion1/evidencias/manifests/scene_manifest.jsonl	198 escenas, 93.1 GB
1	EDA consolidado	Entrega\Final/Situacion1/EDA_consolidado_situacion1.ipynb	Visualizaciones y diagnóstico multifuente
1	Panel seguro	panel_tabular/panel_geovision_cali_situation_hourly_2020_2024_model_safe.parquet	Dataset sin columnas S5P directas
2	Dataset CLIP	outputs/clip_dataset_final_step_by_step/clip_s2_12band_pdf_classes_v5b_high_purity_1500_gsplit/	1500 pares imagen-texto
2	Entrenamiento final	outputs/clip_training_remoteclip_fusion_ksae_v10_v5b_gsplit_seed57_full_logging/manifest_training_final.json	Recall@1, sparsity, MSE, MD5
2	Seed sweep	outputs/clip_training_remoteclip_fusion_ksae_v10_v5b_gsplit_seed_sweep/summary_remoteclip_fusion_ksae_v10_v5b_gsplit_seed_sweep.json	Selección seed57
2	AFE/AFC	outputs/pca_afe_afc_remoteclip_v10_v5b_desde_cero/09_manifest_pca_afe_afc_v10_v5b.json	PCA, Varimax, CFI/RMSEA/SRMR
3	Notebook consolidado	Entrega\Final/Situacion3/notebooks/99_consolidado_situacion3_rubrica.ipynb	Fuente final Situación 3
3	ConvLSTM	Entrega\Final/Situacion3/outputs/metrics/summary_convlstm_bidirectional_spatial.json	Arquitectura, split, test global
3	LOO-CV	Entrega\Final/Situacion3/outputs/metrics/kpi_situacion3_physical_bounds_summary.csv	RMSE, MAE, R^2 , cobertura
3	KPIs	Entrega\Final/Situacion3/outputs/metrics/kpi_situacion3_physical_bounds_summary.csv	Estado final de rúbrica y latencia
3	Moran/LISA/K-Means	Entrega\Final/Situacion3/outputs/mapas/summary_moran_lisa_kmeans.json	9 mapas, I significativo, clusters
4	Backend	fastapi_app/main.py	API REST y validaciones
4	Tests	tests/test_api.py	26/26 pruebas
4	Frontend	geovision-frontend/	React+Vite+Leaflet
4	Producción	https://analiticalastdance-geovision-cali-api.hf.space	API pública

F-B. Versiones de dependencias críticas

La restricción `zarr <3` es obligatoria: la versión 3 cambia el formato de chunk y rompe compatibilidad con los archivos generados durante 2026-04. Esta restricción está pinneada en ambos `requirements-dev.txt` y `requirements-prod.txt`.

F-C. Hardware utilizado

- **Entrenamiento y ETL:** RunPod pod Last_Dance_Modelos_Proyecto3, GPU NVIDIA RTX 3090 (24 GB VRAM), 32 vCPU, 125 GB RAM y volumen persistente S3-compatible de 180 GB montado en `/workspace`.
- **Inferencia:** HuggingFace Spaces `cpu-basic` (2 vCPU, 16 GB RAM, sin GPU). Suficiente para servir los artefactos precomputados de Situación 3 y calcular

consultas espaciales ligeras sin reejecutar RemoteCLIP, ConvLSTM ni PyKrigé en cada request.

- **Desarrollo local:** MacBook Pro M2 (16 GB RAM, macOS 15.5).

F-D. Estructura de directorios del proyecto

El proyecto adopta una estructura raíz reflejada íntegramente en el manifest. El directorio `geovision-cali-hf/data/` contiene los datos crudos (`sentinel2-sentinel-5p/` con 93.1 GB de Sentinel-2 auditados, `panel_zarr/` con S5P en formato Zarr v2 y el panel maestro DAGMA `panel_geovision_*.parquet`). El directorio `outputs/` agrupa los artefactos generados por cada situación: PCA/AFE/AFC sobre RemoteCLIP (`pca_afe_afc_remoteclip_v10_v5b_desde_cero/`), Moran/LISA, variogramas espaciales y espacio-temporales, y los checkpoints CLIP+SAE del entrenamiento `v10/v5b`. Las carpetas `fastapi_app/`,

Cuadro XVI: Versiones pinneadas de dependencias principales.

Paquete	Versión
python	3.11.9
torch	2.1.2+cu118
open_clip_torch	2.24.0
zarr	2.18.2
xarray	2024.5.0
scikit-learn	1.5.0
scikit-gstat	1.0.23
libpysal	4.10
esda	2.5.1
semopy	2.3.10
fastapi	0.115.0
uvicorn	0.30.6
pydantic	2.8.2
react	18.3.1
vite	5.4.2
typescript	5.5.3
react-leaflet	4.2.1

geovision-frontend/, manifest/, docs/ y notebooks/ contienen el backend FastAPI con sus tests, el frontend React+Vite, los manifests MD5, el reporte LaTeX y los 80 notebooks Jupyter del proyecto respectivamente.

REFERENCIAS

[1] F. Liu, D. Chen, Z. Guan, X. Zhou, J. Zhu, Q. Ye, L. Fu, and J. Zhou, "RemoteCLIP: A Vision Language Foundation Model for Remote Sensing," *IEEE Trans. Geosci. Remote Sens.*, 2024.

[2] J. P. Veefkind et al., "TROPOMI on the ESA Sentinel-5 Precursor: A GMES mission for global observations of the atmospheric composition for climate, air quality and ozone layer applications," *Remote Sens. Environ.*, vol. 120, pp. 70–83, 2012.

[3] S. Rey and L. Anselin, "PySAL: A Python Library of Spatial Analytical Methods," *Review of Regional Studies*, vol. 37, no. 1, pp. 5–27, 2007.

[4] M. Mälicke, "SciKit-GStat: A scipy-flavoured geostatistical variogram analysis toolbox written in Python," *Geosci. Model Dev.*, 2022.

[5] A. A. Igolkina and G. Meshcheryakov, "semopy: A Python package for Structural Equation Modeling," *Structural Equation Modeling: A Multidisciplinary Journal*, vol. 27, no. 6, pp. 952–963, 2020.

[6] N. Cressie and H.-C. Huang, "Classes of Nonseparable, Spatio-Temporal Stationary Covariance Functions," *J. Amer. Statist. Assoc.*, vol. 94, no. 448, pp. 1330–1339, 1999.

[7] P. A. P. Moran, "Notes on Continuous Stochastic Phenomena," *Biometrika*, vol. 37, no. 1/2, pp. 17–23, 1950.

[8] L. Anselin, "Local Indicators of Spatial Association: LISA," *Geographical Analysis*, vol. 27, no. 2, pp. 93–115, 1995.

[9] T. Bricken et al., "Towards Monosemanticity: Decomposing Language Models With Dictionary Learning," *Anthropic Transformer Circuits Thread*, 2023.

[10] M. L. Bell, R. D. Peng, and F. Dominici, "The exposure-response curve for ozone and risk of mortality and the adequacy of current ozone regulations," *Environ. Health Perspect.*, vol. 114, no. 4, pp. 532–536, 2006.

[11] J. E. Pachón et al., "Estimating emissions from air pollution sources in Bogotá, Colombia," *Atmos. Environ.*, vol. 178, pp. 84–98, 2018.